

أربعة عشر نموذجاً وخمس أدوات صور وخمس فيديو القراءة لم تتغير، والشك والصورة تغيرا

وشعنا الاختبار إلى ثلاث شركات وثلاث مراحل، بحكم أعمى من قاضيين مستقلين على ثلاثمئة صورة. أرخص نموذج ما زال يقرأ الأبعاد المطبوعة بلا خطأ؛ نموذج أرخص منه صار الوحيد الذي يرفض إعطاء رقم لرسم لا تُغلق؛ وأداة صور واحدة فقط تُنقع القاضيين بأن البلاطة هي البلاطة.

نماذج الاستخراج: ١٤ أدوات الصور: ٣٠٠ × ٥ صورة أدوات الفيديو: ٥ الأحكام: +٦٠ الإنفاق: \$ ٥٢٠ التاريخ: ٧ سبتمبر ٢٠٢٦

00 الجواب أولاً: التوليفة لم تتغير في القراءة، وتغيرت في الشك والصورة

الخلاصة

وشعنا المصفوفة من ٧ نماذج Google إلى ١٤ نموذجاً من ثلاث شركات، وأضفنا مرحلتي الصورة (٥ أدوات ٢٠ × بلاطة ٣ × غرف = ٣٠٠ صورة بحكم أعمى من قاضيين مستقلين) والفيديو (٥ أدوات ٣ × غرف). النتيجة: أرخص نموذج في القائمة ما زال يقرأ الأبعاد المطبوعة بلا خطأ، لكن ظهر نموذج أرخص منه يُحسن الشك: `gpt-5.6-sol` هو الوحيد الذي يرفض إعطاء رقم للرسم التي لا تُغلق في التشغيلات الخمس كلها. وفي الصور، **Gemini Flash Image** وحده يُنتج ما يقبله القاضيان «البلاطة نفسها» في أكثر من نصف الحالات: Recraft و Stability عند ٢%.

المرحلة	الموصى به	لماذا	ما تغيّر عن ٦ سبتمبر
قراءة الأبعاد (نصّ · قصاصة · مخطط مصوّر)	<code>gemini-3.5- flash-lite</code>	صفر خطأ في كل الغرف المرجعية. ٥-٢ ثوانٍ, ١,٣-٠,٠ سنت — لم يتفوّق عليه أحد من ١٣ نموذجاً آخر	● ثابت
كشف التعارض في رسمه العميل	<code>gpt-5.6-sol</code>	٥/٥ على الرسمه الأصلية و٥/٥ على المصغّرة, يعيد <code>null</code> بدل رقم مخمّن, ١٨,٠ سنت مقابل ٢,٠ ل Flash-3.5	● تغيّر كان Flash-3.5 (٤/٥)
الـ PDF الخام	● لا يُرسل	لم نرسله لأي نموذج جديد هذه الجولة — نحوّله بـ <code>pdftoppm -r 150</code> أولاً	● ثابت
صورة الغرفة بالبلاطة	Gemini Flash) Image <code>gemini-3.1- flash-image</code> (	«البلاطة نفسها» ٥٧% عند قاضي OpenAI و ٩٢% عند قاضي Google ١١٠ ثانية ٦,٧٠ سنت. Pro أعلى ٢× بلا فرق, و Lite أرخص لكنه يخطئ البلاطة في النصف	● جديد
فيديو الجولة	ffmpeg حتمي أولاً	انظر VS٠ — القاضيان حكما على ثلاثة إطارات من كل مقطع	● جديد

01 ما اختُبر: ثلاث مراحل، ثلاث شركات، وقاضيان لا يعرفان من رسم

الاستخراج: ٧ نماذج جديدة — `gpt-5.6-luna` · `gpt-5.6-sol` · `gpt-5.6-terra` من OpenAI, و `claude-opus-5` · `claude-sonnet-5` · `claude-haiku-4-5` · `claude-opus-4-5` من Anthropic — على السيناريوهات الستّة (بلا الـ PDF الخام) بخمس تشغيلات، بنفس البرومبت والحقيقة المرجعية. وأعيد `gemini-3.1-pro-preview` و `gemini-3.8-flash` من خادم DigitalOcean لأن الشبكة المحلية كانت تقطعهما. المعرّفات كلها من قوائم الخدمات لا مخمّنة. Opus-5 و Sonnet-5 بتفكير تكيفي وبلا `temperature` (الواجهة ترفضها): الباقي بحرارة 1.0 كالجولة الأولى.

الصورة: ٢٠ بلاطة حقيقية من niceramics.com (٩ منها عينة مسطحة و١١ لقطة غرفة تعرض البلاطة — وهذا ما يجده العميل فعلاً في الكتالوج) 3×3 غرف فارغة بترخيص مشاع 5×5 أدوات: Gemini Lite/Flash/Pro Image (البلاطة والغرفة كمرجعين في طلب واحد) Recraft V3 (يُصنع style من البلاطة ثم imageToImage على الغرفة) Stability (control/style-transfer): الغرفة أساساً والبلاطة أسلوباً). الترقيم أعمى؛ والحكم بقاضيين من شركتين غير شركة الأداة قدر الإمكان — gpt-5.6-sol و gemini-3.8-flash — كل يرى البلاطة المرجعية والصورة المولدة ويجب: هل هي البلاطة نفسها؟ أمانة النقشة واللون /٥؟ هل بقيت الغرفة؟

الفيديو: أفضل صورة لكل غرفة بمجموع درجات القاضيين $\rightarrow$ ffmpeg حتمي $\cdot$ Veo 3.1 Fast $\cdot$ Veo 3.1 Lite $\cdot$ Sora 2. ثمانية ثوانٍ 720p. ثم ثلاثة إطارات من كل مقطع إلى القاضيين نفسهما.

ما لم يكتمل — وسببه

رصيد Anthropic (\$٥) نفذ في منتصف S5/S6 فتوقفت ٣٠ خلية من Sonnet-5 و Haiku-4.5 و Opus-4.5؛ شُحن الرصيد وأُكملت من الخادم في الليلة نفسها، وجدول S5/S6 أدناه كاملة. **Mistral OCR 4.1** شُغل بعد توثيق إطفاء التدريب (٤ مُدخّلات): على المخطط الكامل (S5 و S6) قرأ **جدول العنوان فقط** ولم يلتقط أي رقم بُعد داخل الرسم (٩/٠ في كليهما)، وعلى القصاصة قرأ ٣ من ٥ أبعاد مطبوعة (ضاع 600 وقرئ 190 على أنه 210)، وعلى الرسمة اليدوية لا شيء (٤/٠) — أقل من ثانيتين للمُدخّل. **ليس طبقة قراءة أبعاد:** يعامل الرسم الهندسي كصورة ويُخرج النصوص الجدولية حوله؛ يسقط. القاضي الثاني كان مقرراً Sonnet-5 فحلّ محلّه gpt-5.6-sol للسبب نفسه، ثم أُضيف Sonnet-5 قاضياً ثالثاً بعد الشحن (عموده في جدول S٠٦). Document AI تُخطي بقرار، و gpt-image-2 و FLUX و Runway مُقصاة من الدراسة الصفرية.

02 النصّ والقصاصة: أربعة عشر نموذجاً، جواب واحد

رسالة العميل بالأبعاد (S1): ١٤/١٤ نموذجاً أعطى ٤٦,٠٠ م في التشغيلات الخمس كلها. الفرق الوحيد هو السعر والزمن: GPT-5.6 عند ٠,٦-٠,٨ سنت، Lite عند ٠,٩، Opus-5 عند ٢,٦. قصاصة المخطط (S3):

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الحكم
Lite-3.1 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٢,٣	٠,١٢	● صفر خط
Lite-3.5 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٢,٣	٠,١٢	● صفر خط
Flash-3.5 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	١٠,١	١,١٣	● صفر خط
Flash-3.6 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٨,٠	٠,٨٣	● صفر خط
Flash-3.7 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٤,٢	٠,٥٣	● صفر خط
Flash-3.8 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٧,٨	٠,٥٨	● صفر خط
Pro-3.1 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	١٧,٢	٣,٧٥	● صفر خط
GPT-5.6-luna OpenAI	٥/٥	٣-٣	٣٦,٦	٢/٣	١,٨	٥,٨	٠,١١	● جزئي

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الحكم
GPT-5.6-sol OpenAI	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٨,٩	٠,١١	● صفر خط
GPT-5.6-terra OpenAI	٥/٥	٤-٣	٣٦,٣	٣/٣	٠,٠	٤,٨	٠,٠٩	● صفر خط
Opus-5 Anthropic	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	١٤,٢	٣,٧٤	● صفر خط
Sonnet-5 Anthropic	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٢٤,٧	٢,٦١	● صفر خط
Haiku-4.5 Anthropic	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٥,٨	٠,٥١	● صفر خط
Opus-4.5 Anthropic	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٧,٢	٢,٤٥	● صفر خط

الخطأ الوحيد في القصاصة كان **gpt-5.6-luna** الذي قرأ الحَمَام ٦,٣ بدل ٦,٠ في التشغيلات الخمس (٣٦,٦ بدل ٣٦,٣) — و **gpt-5.6-terra** الذي أضاف فراغاً رابعاً غير موجود في تشغيلة. Haiku-4.5 صحيح في الوسيط لكنه الوحيد الذي تشَّتت (٥% بين التشغيلات). ● مؤكّد ١٤٠ نموذجاً × ٥

03 الرسمة التي لا تُغلق: من يقول «لا أعرف»؟

الرسمة نفسها من الجولة الأولى: ارتفاع اليسار ٣ م واليمين ١ + ٢,٥ = ٣,٥ م، فلها ثلاثة أجوبة «صحيحة» (٠,١١,٠). (١٣,٢٥٠ ١٣,٠) ولا جواب واحد. المقياس هنا ليس الرقم، بل: هل صرّح النموذج بالتعارض؟

النموذج	كشف التعارض	القيم التي أعطاها	ثانية	سنت	الحكم
Lite-3.1	٠ / ٥	١٣,٢٥٠١٣,٠	٥,٦	٠,١٠	صامت ●
Lite-3.5	٠ / ٥	١١,٠	٤,٨	٠,٠٩	صامت ●
Flash-3.5	٤ / ٥	١٣,٢٥٠١١,٠	٢٠,٠	٢,٠١	يكشف ●
Flash-3.6	٠ / ٥	١٣,٠٠١١,٠	٣٠,٧	٢,٠٧	صامت ●
Flash-3.7	٠ / ٥	١٦,٠٠١٥,٠٠١٣,٢٥٠١١,٥	١٥,٤	١,٤٠	صامت ●
Flash-3.8	٢ / ٥	١٣,٢٥٠١١,٥٠١١,٠	٦٣,١	٨,٢٣	أحياناً ●
Pro-3.1	٤ / ٥	١٤,٢٥٠١٣,٢٥٠١١,٥	٣٥,٩	٦,٨١	يكشف ●
GPT-5.6-luna	٣ / ٥	١١,٥٠١١,٠	١٧,٠	٠,٢٠	أحياناً ●
GPT-5.6-sol	٥ / ٥	لا رقم	١٦,٣	٠,١٨	يكشف ●
GPT-5.6-terra	٠ / ٥	١٣,٠٠١١,٠	١٨,١	٠,٢٣	صامت ●
Opus-5	٠ / ٥	١٣,٠٠١١,٠	٢٣,٦	٧,٣٥	صامت ●
Sonnet-5	٠ / ٥	١٣,٠٠١١,٠	٢٩,٥	٣,٨٦	صامت ●
Haiku-4.5	٠ / ٥	٢٢,٥٠١٦,٢٥٠١٦,٠٢٥٠١٤,٧٧٥	٥,٧	٠,٥٣	صامت ●
Opus-4.5	٠ / ٥	١٣,٠٠١٢,٢٥	١٤,١	٣,٣٨	صامت ●

النتيجة الجديدة

gpt-5.6-sol كشف التعارض في ٥/٥ — وفعل ما لم يفعله أحد: أعاد
 floor_area_m2: null وكتب في الدليل «الارتفاع الكلي المكتوب ٣ م بينما ٢,٥ + ١ = ٣,٥ م».

Flash-3.5 و Pro-3.1 يكشفان ٤/٥ لكنهما يعطيان رقماً مع ذلك. عائلة Claude الأربعة صامتة ٠/٥ وتعطي رقماً ثابتاً (١١,٠ أو ١٣,٠) بثقة — و Haiku-4.5 أسوأ: أرقام من ١٤,٨ إلى ٢٢,٥ لا يفترها أحد. على النسخة المصغرة (S2b) ١٦٠px تكرر الترتيب نفسه: sol ٥/٥, luna ٤/٥, Pro ٣/٥.

ما يعنيه هذا للتصميم: طبقة «الرأي الثاني» لا تحتاج نموذجاً غالياً مفكراً؛ تحتاج نموذجاً مسموحاً له أن يرفض. sol يكلف ١/٨ سنت للاستدعاء — عُشر Flash-3.5 وثلاثون ضعف أرخص من Pro.

● رسمة واحدة — يُعقَّم بعد ١٠ رسومات

04 المخطط الكامل: من يقرأ الرقم المطبوع، ومن «يقيس» بدلاً منه

الدور الأرضي كصورة راستر (S5) والـ PDF نفسه بعد تصييرنا (S6). خمس غرف مرجعية أبعادها مطبوعة على الرسم بالسنتيمتر. المقياس: كم غرفة أصابها النموذج بخطأ $\geq 2\%$.

S5 — صورة راستر للدور الأرضي

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف %	ثانية	سنت	الحكم
Lite-3.1 Google	٥/٥	١٤-١٢	٢٧١,٧٤	٥/٥	٠,٠	٦,٥	٠,٢٨	● صفر
Lite-3.5 Google	٥/٥	١٣-١٣	٢٨٣,٦٧	٥/٥	٠,٠	٥,١	٠,٢٩	● صفر
Flash-3.5 Google	٥/٥	١٥-١٣	٣٣٨,٧٩	٤/٥	٤,٠	٢٤,٢	٣,١١	● جزئي
Flash-3.6 Google	٥/٥	١٦-١٤	٣٢٤,٣٦	٥/٥	٠,٠	٢٠,٦	٢,٢٩	● صفر

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الحكم
Flash-3.7 Google	٥/٥	١٣-١١	٣٢٥,٢١	٥/٥	٠,٠	٨,٣	١,٢٠	● صفر
Flash-3.8 Google	٥/٥	١٣-١١	٢٥٣,٧٢	٥/٥	٠,٠	٩,٥	١,٣٩	● صفر
Pro-3.1 Google	٥/٥	١٤-١٣	٢٣٥,٨٤	٥/٥	٠,٠	٦٣,٠	١٢,١٩	● صفر
GPT-5.6-luna OpenAI	٥/٥	١٦-١٤	٢٨٢,٤٦	١/٥	٨,٥	٤٩,٠	٠,٦٠	● ضعيف يقرأ الأثر المطبوع خطأً (١٠) بدل ٥٦٠ بدل ٥٠٠
GPT-5.6-sol OpenAI	٥/٥	١٨-١٤	٢٢٧,١١	٢/٥	٧,٣	٨٠,٨	٠,٧٢	● ضعيف يقرأ الأثر المطبوع خطأً (١٠) بدل ٥٦٠ بدل ٥٠٠
GPT-5.6-terra OpenAI	٥/٥	١٥-١٢	٢١٦,٦٩	٢/٥	١٣,٤	٤٠,٨	٠,٥٤	● ضعيف يقرأ الأثر المطبوع خطأً (١٠) بدل ٥٦٠ بدل ٥٠٠

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الحكم
Opus-5 Anthropic	٥/٥	١٨-١٥	٣٣٧,٤٢	٤/٥	٤,٠	٧٦,٣	١٧,٩٠	● جزئي المطبخ مقيس الرسم لا من الرق المطبو
Sonnet-5 Anthropic	١/٥	١٥-١٥	٣٩٥,٨٦	٤/٥	٤,٠	٢٠١,٩	١٦,٧٥	● جزئي
Haiku-4.5 Anthropic	٥/٥	١٣-١٢	٣١٢,١٣	٠/٥	٧٩,١	١٥,٣	١,١٩	● صغير
Opus-4.5 Anthropic	٥/٥	١٤-١٤	٢١٣,٢٤	٠/٥	٧٢,٤	٢٠,٨	٦,١١	● صغير

S6 — الـ PDF نفسه بعد pdftoppm -r 150

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الح
Lite-3.1 Google	٥/٥	١٤-١٣	٢٥٩,٨٢	٥/٥	٠,٠	٥,٩	٠,٢٩	●
Lite-3.5 Google	٥/٥	١٥-١٥	٣٦٣,٨١	٤/٥	٤,٠	٥,٣	٠,٣٣	●
Flash-3.8 Google	٥/٥	١٤-١٢	٢٥٦,٨٨	٥/٥	٠,٠	١١,٣	١,٤٤	●

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الح
Pro-3.1 Google	٥/٥	١٨-١٢	٢٦٦,٦٧	٥/٥	٠,٠	٥٢,٧	١٠,٧٠	●
GPT-5.6-luna OpenAI	٥/٥	١٦-١٣	٢٩٦,٣٢	٣/٥	١٠,٢	٣٥,٣	٠,٥٦	●
GPT-5.6-sol OpenAI	٥/٥	٢٠-١٥	٢٢١,٢٥	٤/٥	٢,٢	٩٨,٣	٠,٧٥	●
GPT-5.6-terra OpenAI	٥/٥	١٧-١٢	٢٨١,٤٨	٣/٥	٣,٧	٣٨,٠	٠,٥٣	●
Opus-5 Anthropic	٥/٥	١٦-١٥	٣٧١,٧٨	٥/٥	٠,٠	٦١,١	١٦,٥٢	●

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الح
Sonnet-5 Anthropic	٤/٥	١٥-١٥	٣٨٨,٣٦	٤,٠/٥	٧,٥	١٣٨,٧	١٣,٨١	●
Haiku-4.5 Anthropic	٥/٥	١٤-١٢	٢١٩,٠	٠/٥	٥٤,٥	١٤,٧	١,٢١	●
Opus-4.5 Anthropic	٥/٥	١٦-١٤	٢٣٥,٧١	١/٥	٢٦,٧	٢٣,٠	٦,٤٢	●

تفسير

عائلة GPT-5.6 تجد الغرف الخمس كلها لكنها **تقرأ الأرقام المطبوعة خطأً** — 875×590 بدل ٥٦٠. 430×500 بدل ٥٥٠. 250×200 بدل ٢٢٠ — وهي الأرقام نفسها التي أخطأتها Gemini على الـ PDF الخام في الجولة الأولى. الفرق أن Gemini تُصيبها على الصورة وGPT لا. وتستغرق ٤٠-١٠٠ ثانية للمخطط (تفكير طويل) مقابل ٥ ثوانٍ لـ Lite. Opus-5 يقرأ أربعاً من خمس صحيحة، لكنه في المطبخ ترك الرقم المطبوع و**قاس من الرسم** فأعطى ١٥,٠ بدل ٢٣,٦٥ — ثم أصاب الخمس على S6 بتكلفة ١٦,٥ سنت و٦١ ثانية. Lite-3.5 وFlash-3.8 يصيبان الخمس بأقل من سنت ونصف. بقية عائلة Claude بعد الشحن: **Sonnet-5** دقيق حين يُكمل (٤/٥ على S6 بخطأ ٧,٥%) لكنه **استنفد سقف ١٦ ألف رمز** في ٤ من ٥ تشغيلات على S5 (تفكير تكتيفي يلتهم الميزانية) عند ١٤٠-٢٠٠ ثانية و١٧-١٤ سنتاً؛ **Haiku-4.5** يجد الغرف الخمس لكن بخطأ ٥٥-٧٩% في مساحاتها (٠/٥ مطابق) — يقرأ الأرقام ولا يربطها بالغرفة الصحيحة؛ **Opus-4.5** ١/٥ مطابق بخطأ ٢٧%. لا واحد منها يقترب من Lite.

05 Flash-3.8 وPro-3.1 من شبكة الإنتاج: الحكم المعلق خُسم

في الجولة الأولى قُطع Pro-3.1 ١١ مرة من ٢٥ وُعُلّق الحكم عليه. أُعيد النموذجان من droplet في DigitalOcean: **صفر قطيعة شبكية** في ٦٣ خلية (ثلاث 503 من خادم Google نفسه أُعيدت فنجحت). فتبين أن Pro-3.1 يصيب الغرف الخمس ٥/٥ على S5 وS6 ويكشف تعارض الرسمة ٤/٥ — لكنه يستغرق ٣٥-

٨٣ ثانية ويكلف ٣-١٥ سنتاً للاستدعاء، أي لا يضيف شيئاً على Lite-3.5 في القراءة ولا على sol في الشكّ. وبثلاثين ضعف سعرهما. Flash-3.8 ثابت كما كان، والقطيعة التي أصابته على صور الجوال الكبيرة كانت شبكية أيضاً.

الدرس الذي يهّم مسار الإنتاج: الشبكة المحلية تُسقط أي اتصال يطول نحو دقيقتين — أصابت OpenAI أيضاً على S5/S6 (٦/٦ قبل الانتقال إلى الخادم). أي قياس زمن أو قطيعة يُجرى من الإنتاج لا من المكتب.

● مؤكد ٦٣٠ + ٧٠ خلية من الخادم

06 الصور: أداة واحدة تُقنع القاضيين، واثنان لا تُقنعان أحداً

٣٠٠ صورة، كلٌ منها حُكمت مرتين بلا معرفة الأداة. السؤال الذي يهّم العميل واحد: هل هذه هي البلاطة التي في الكتالوج؟

الأداة	صور	«البلاطة نفسها» — قاضي OpenAI	— قاضي Anthropic	— قاضي Google
Gemini Lite Image	٦٠/٦٠	٣٥%	٣٢%	٦٨%
Gemini Flash Image	٦٠/٦٠	٥٧%	٣٠%	٩٢%
Gemini Pro Image	٦٠/٦٠	٥٣%	٢٧%	٩٢%
Recraft V3	٦٠/٦٠	٢%	٠%	٢%
Stability	٦٠/٦٠	٢%	٣%	٣%

ثلاثة قضاة من ثلاث شركات، وثلاث صرامات: قاضي Google أكثر تساهلاً مع صور Google (٩٢٪)، قاضي OpenAI في الوسط (٥٧٪)، وقاضي Anthropic (Sonnet-5) الأشد — يعطي الثلاثة من Gemini نحو ٣٠٪ بلا فرق بينها (٣٢٪ ٣٠٪ ٢٧٪) ويُبقي Recraft وStability عند ٠٪ و٣٪. ما يتفق عليه الثلاثة بلا استثناء: **Stability وRecraft يسقطان** (٩٣-٩٨٪ اتفاق على «ليست البلاطة»). ما يختلفون فيه: هل Flash أفضل من Lite وPro — قاضيان يقولان نعم بفارق واضح، والثالث لا يرى فرقاً. لذلك الترتيب المعتمد **Gemini » Recraft ≈ Stability** مؤكّد، وتفضيل Flash داخل عائلة Gemini • مرجّح لا مؤكّد — يُحسم بعينيات مسطّحة وبشر يحكمون.



بلاطة زهور مائية (T13) في المطبخ نفسه: المرجع ثم Gemini Lite · Flash · Pro · Recraft · Stability. الثلاثة الأولى تنقل النقشة: Recraft يضع بلاطة أخرى: Stability يترك الأرضية خشباً ويرسم الزهور على الجدار.

ما الذي يُفضل الأداة؟


الأداة	مرجع عيّنة مسطّحة (٩ بلاطات) نفسها/٠ نقشة/٥	مرجع لقطة غرفة (١١ بلاطة) مطبخ نفسها/٠ غرفة/٥	حقام
Gemini Lite Image	٢,٨ • ٢٦٪	٣,٠ • ٤٢٪	٣,٥ • ٣٥٪
Gemini Flash Image	٣,٧ • ٦٧٪	٣,١ • ٤٨٪	٤,٠ • ٥٠٪
Gemini Pro Image	٣,٦ • ٦٣٪	٣,٢ • ٤٥٪	٤,٢ • ٦٠٪

الأداة	مرجع عيّنة مسطحة (٩ بلاطات) نفسها% · نقشة/٥	مرجع لقطة غرفة (١١ بلاطة) مطبخ نفسها% · غرفة/٥	حمام
Recraft V3	٠,٦ · %٤	٠,٥ · %٠	٣,٩ · %٠
Stability	١,١ · %٠	١,٢ · %٣	٢,٥ · %٠

- **نوع المرجع يحسم:** Pro و Flash يصيبان «البلاطة نفسها» في ثلثي الحالات حين يكون المرجع عيّنة مسطحة. وفي أقل من النصف حين يكون لقطة غرفة من الكتالوج — لأن الأداة لا تعرف أي سطح في اللقطة هو البلاطة. **الكتالوج الحالي أغلبه لقطات غرف** (١١/٢٠) — وهذا بند تجهيز بيانات، لا بند نموذج.
- **Lite يخطئ البلاطة لا الغرفة:** يحفظ الغرفة (٣,٧/٥) لكنه يضع نقشة قريبة لا مطابقة (٣٥%). أرخص بالنصف من Flash. ولا يساوي الفرق.
- **Pro لا يفوق Flash** (٥٣% مقابل ٥٧%) وهو أبطأ ٢× وأعلى ٢×، وأخرج في بعض الحّمّات صورة مزدوجة جنباً إلى جنب.
- **Recraft** يحفظ الغرفة جيداً (٣,٨/٥) لكن **style** المستخرج من البلاطة يُنتج «بلاطة بروح المرجع» لا المرجع — ٢% فقط. **Stability** بـ style-transfer إمّا يُتلف الغرفة (الإعداد الافتراضي) أو يطلي الجدران والسقف بالنقشة ولا يفهم «الأرضية فقط» — حفظ الغرفة ١,٩/٥. كلاهما يسقط بغضّ النظر عن السعر.



Gemini Lite Image · kitchen · T11 · IMG-087 · 16.0/20



Gemini Lite Image · bathroom · T14 · IMG-161 · 16.0/20



Gemini Lite Image · standard · T17 · IMG-061 · 16.0/20



Gemini Flash Image · kitchen · T18 · IMG-091 · 16.0/20



Gemini Flash Image · bathroom · T14 · IMG-069 · 17.0/20



Gemini Flash Image · standard · T13 · IMG-096 · 17.0/20



Gemini Pro Image · kitchen · T14 · IMG-004 · 16.0/20




Gemini Pro Image · bathroom · T13 · IMG-086 · 17.0/20




Gemini Pro Image · standard · T04 · IMG-233 · 17.0/20



Recraft V3 · kitchen · T15 · IMG-114 · 16.0/20




Recraft V3 · bathroom · T15 · IMG-031 · 10.0/20




Recraft V3 · standard · T04 · IMG-218 · 11.0/20



Stability · kitchen · T19 · IMG-211 · 11.0/20



Stability · bathroom · T15 · IMG-028 · 12.0/20



Stability · standard · T20 · IMG-099 · 16.0/20

أفضل صورة لكل أداة (صفوف) في كل غرفة (أعمدة) بمجموع درجات القاضيين — حتى «أفضل» Recraft وStability ليست البلاطة المطلوبة.

لكل غرفة الصورة الأعلى درجةً عند القاضيين (, kitchen: **IMG-126** , bathroom: **IMG-244** standard :**IMG-096**). المقطع ٨ ثوانٍ 720p. والحكم على ثلاثة إطارات (البداية · المنتصف · النهاية) مقابل الصورة المصدر.

الأداة	مقاطع	النقشة ثابتة — قاضي OpenAI	— قاضي Google	ثانية	\$ للثلاثة	ملاحظة
ffmpeg (حتمي) ffmpeg zoompan	٣/٣	٣/٣ · ٤,٣	٣/٣ · ٤	١	٠,٠٠	
Veo 3.1 veo-3.1-generate-preview	٣/٣	٢/٣ · ٣	٢/٣ · ٣,٧	٦٨	٩,٦٠	
Veo 3.1 Fast veo-3.1-fast-generate-preview	٣/٣	٠/٣ · ١,٧	١/٣ · ٣	٥٧	٢,٤٠	
Veo 3.1 Lite veo-3.1-lite-generate-preview	٣/٣	١/٣ · ٣	١/٣ · ٣,٣	٤٦	١,٢٠	
Sora 2 sora-2	٣/٣	٢/٣ · ٣,٣	١/٣ · ٣	١٢٦	٢,٤٩	

الإطار الأول في كل مقطع توليدي يطابق المصدر (٤-٥/٥ عند القاضيين) لأنه الصورة نفسها تقريباً؛
التدهور يبدأ في المنتصف ويكتمل في الإطار الأخير: بلاطة الحمام الشيفرونية تحوّلت عند Veo 3.1
 Fast إلى بلاطة أخرى (٥ → ١). وعند Sora في الحمام اختفت من الإطار الأخير (٤ → ٠). الغرفة الأسهل
 هي المطبخ (بلاطة خشبية النقشة، حركة أمامية بسيطة) — هناك ثبت Veo 3.1 و Sora عند
 القاضيين. الترتيب: **Veو Fast > Veو Lite > Sora 2 ≈ Veو 3.1 > ffmpeg**. و Veو 3.1 يكلف
 \$ ٣,٢ للمقطع مقابل \$ ٠,٨٣ لـ Sora و صفر لـ ffmpeg.



الحمام: الإطار الأول والأوسط والأخير لأربع أدوات. ffmpeg (يسار) لا يتغير: الثلاثة الأخرى تبدأ صحيحة وتنتهي
 ببلاطة أخرى أو بلا بلاطة.

ffmpeg لا يعيد رسم بكسل واحد — النقشة ثابتة **بالتعريف** وبتكلفة حوسبة تُقاس بأجزاء السنت (٦, ٠ ثانية
 للمقطع). التوليدي يُقاس بما يفعله بالنقشة، لا بجمال الحركة.

gemini-3.5-flash-lite

القراءة

كل مُدخَل يبدأ هنا (نصّ · قصاصة · مخطط مصوّر · PDF بعد تصديرنا). ١٣ نموذجاً آخر لم يتفوّق عليه في غرفة واحدة، وأغلبها أبطأ وأعلى بعشرات الأضعاف.

كود، لا نموذج

التحقّق الحتمي

إغلاق المضلّع، مطابقة العدّ، رفض التشغيلية الشاذّة، ومحلّل JSON متسامح — ثلاث خلايا هذه الجولة (Flash-3.5، ٢× Opus-5) أخرجت JSON صحيحاً بفاصلة زائدة أو محرف تحكّم، والمحلّل الصارم يراها فشلاً.

gpt-5.6-sol

الشكّ — عند العلم فقط

حين ترفع الطبقة الحتمية علماً: يُستدعى ليقول إن كانت الرسمة لا تُغلق — ويقولها ٥/٥ ويرفض الرقم. ١٨، سنت و١٦ ثانية. مزوّد ثانٍ من شركة أخرى = احتياط تشغيلي أيضاً.

gemini-3.1-flash-image + عيّينات مسطّحة

الصورة

البلاطة والغرفة في طلب واحد، ٦،٧ سنت، ١١ ثانية. الشرط الذي يرفع الإصابة من النصف إلى الثلثين ليس النموذج بل تصوير كل موديل عيّنة مسطّحة بدل لقطة الغرفة.

ffmpeg على الصورة المعتمّدة

الفيديو

الحكم في ٧S: التوليدي يُضاف فقط حيث يثبت القاضيان أن النقشة لم تتغيّر.

القرارات التي أقفلتها الجولتان — وأين تُبِتت

القرار	دليله	أين تُبِتت
الـ PDF يُحوّل عندنا) (pdfptoppm -r 150 ولا يُرسل خاماً لأي نموذج	الجولة ١: كل النماذج قرأت الأرقام نفسها خطأً من الخام، وصفر خطأً بعد التصيير	ai-estimator-spec.md ٢S هـ · طلب التغيّر -CR-02 01

القرار	دليله	أين نُبِت
طبقة القراءة = OCR لا : gemi-3.5-flash-lite متخصّص	١٣ نموذجاً لم يتفوّق عليه: Mistral OCR ٩/٠ على المخطط	٢٥ هـ CR-02-02
طبقة الشكّ = gpt-5.6-sol بسياسة » أفضل من رقم« والطبقة الحتمية تقبل null وتُسأل	٥/٥ كشف تعارض الرسمة ورفض الرقم: الباقون صامتون أو يَحْمَنون	٢٥ هـ CR-02-03
محلّ JSON متسامح (فاصلة زائدة · محرف تحكّم · شطيّة بعد الكائن)	٣ خلايا صحيحة كان الصارم سيُسقطها	٢٥ هـ
الصورة = gemi-3.1-flash-image بشرط عيّنة مسطّحة لكل موديل: Recraft وStability يسقطان	٤٨% → ٦٧% بالعيّنة المسطّحة: الاثنان ٣٠-٣% عند ثلاثة قضاة	٢٥ هـ CR-02-04 (بند تجهيز بيانات في BRD v1.1.0)
الفيديو = ffmpeg على الصورة المعتمّدة: التوليدي غير معتمد	ثابت ٣/٣: التوليدي يتدهور في الإطار الأخير	٢٥ هـ

09 ما انقُتل، وما لم يُتحقّق، وما مصدره واحد

انقُتل في هذه الجولة

- «Flash-3.5 هو أفضل كاشف للتعارض» — sol يفوقه (٥/٥ مقابل ٤/٥) ويرفض الرقم بدل أن يعطيه، بعُشر التكلفة.
- «Pro-3.1 محجوب شبكياً فحكمه معلّق» — من الخادم لا قطيعة، ولا ميزة.
- «النموذج الأعلى يقرأ المخطط أفضل» — Opus-5 قاس المطبخ من الرسم متجاهلاً الرقم المطبوع؛ GPT-5.6 أخطأ الأرقام المطبوعة نفسها التي أخطأتها Gemini على الـ PDF الخام.

- «Recraft مرشح امتثالياً فيجرب» — امتثاله لا يشفع له: ٢% «البلاطة نفسها».

غير متحقق

- أسعار GPT-5.6 (٢٠,٢٠/١,٢٠ \$ للمليون) مفترضة من الدراسة الصفريّة — الرموز مقيسة، السنوات لا. أسعار Gemini و Anthropic الصور و Veo منشورة.
- القاضيان نموذجان لا بشر. اتفاقهما على الفاشل تام، واختلافهما على الناجح واضح — فالنسب المطلقة تُقرأ كترتيب لا كقياس.
- Sora 2 بسعر مفترض (١٠,٠ \$/ث) من الدراسة الصفريّة.

مصدر واحد

- **حدّ معلّن:** كل استنتاج في ٠.٣S و ٠.٦S مبنيّ على رسمة واحدة ومخطط واحد وثلاث غرف. لا يُرفع إلى «مؤكّد» قبل عشر رسومات وعشر لقطات غرف من عملاء حقيقيين — وهذا يُجمّع بعد الإطلاق لا قبله، لأن الأداة تسجّل كل مُدخل (**audit trail**) ٤S من المواصفة).
- رسمة يد واحدة تحكم كل استنتاج ٠.٣S. عشر رسومات من عملاء حقيقيين قبل تثبيت sol في التصميم.
- مخطط واحد (الدور الأرضي نفسه) لكل نتائج ٤S.
- ثلاث غرف فقط، ومصوّرة بترخيص مشاع لا بحوال العميل. غرفة العميل الحقيقية (إضاءة رديئة، زاوية عشوائية) لم تُختبر.

10 خيارات التوليفة وتكلفتها — عند ١٠,٠٠٠ طلب في الشهر

كل خيار أدناه توليفة كاملة يمكن للعميل أن يطلبها كما هي، وتكلفتها مجموع وحدات **مقيسة في هاتين الجولتين** (وسيط الرموز × السعر المنشور، وسعر الصورة والمقطع كما دُفع فعلاً) لا مفترضة. الافتراضات التشغيلية الوحيدة معلنة تحت الجدول وتُصحّح بعد أول شهر حيّ.

#	الخيار	مكوناته (سنت للطلب)	سنت/طلب	\$ /شهر
A	القراءة فقط Lite-3.5 يقرأ + الطبقة الحتمية تحسب + تأكيد بشري. لا شك آلي، لا صور، لا فيديو.	قراءة (Lite-3.5) ٠,١٧ + تصوير PDF ٠,٠١	٠, ١٧	١٧
B	القراءة + الشك (النواة الموصى بها) ● موصى به A + gpt-5.6-sol يُستدعى فقط حين ترفع الطبقة الحتمية علماً (٢٥% من الطلبات).	قراءة (Lite-3.5) ٠,١٧ + تصوير PDF ٠,٠١ + شك (gpt-5.6-sol ٢٥% × ٠,٠٨)	٠, ٢٥	٢٥
C	النواة + صور الغرف B + صورة لكل غرفة بـ Gemini Flash Image (3 غرف للطلب).	قراءة (Lite-3.5) ٠,١٧ + تصوير PDF ٠,٠١ + شك (gpt-5.6-sol ٢٥% × ٠,٠٨ + صور Flash Image ×3) ٢٠,١٠	٢٠, ٣٥	٢, ٠٣٥
C-lite	النواة + صور أرخص (Lite Image) مثل C لكن بـ Gemini Lite Image — نصف السعر وثلاث الدقة.	قراءة (Lite-3.5) ٠,١٧ + تصوير PDF ٠,٠١ + شك (gpt-5.6-sol ٢٥% × ٠,٠٨ + صور Lite Image Image ×3) ١٠,١٠	١٠, ٣٥	١, ٠٣٥
D	النواة + صور + فيديو حتمي C + مقطع ٨ ثوانٍ يُجمَع بـ ffmpeg من الصور المعتمدة (النقشة ثابتة بالتعريف).	قراءة (Lite-3.5) ٠,١٧ + تصوير PDF ٠,٠١ + شك (gpt-5.6-sol ٢٥% × ٠,٠٨ + صور Flash Image ×3) ٢٠,١٠ + فيديو ٠,٠٥	٢٠, ٤٠	٢, ٠٤٠

#	الخيار	مكوناته (سنت للطلب)	سنت/طلب	\$ /شهر
E	النواة + صور + فيديو Sora 2 C + مقطع توليدي ٨ ثوانٍ بـ Sora 2 (1 للطلب).	قراءة (Lite-3.5) ٠,١٧ + تصيير PDF ٠,٠١ + شك (gpt-5.6-sol) ٢٥% ٠,٠٨ + صور (Flash) ٢٠,١٠ (Image ×3) + فيديو Sora 2 ٨٣,٠٠	١٠٣,٣٥	١٠,٣٣٥
F	النواة + صور + فيديو Veو 3.1 C + مقطع توليدي ٨ ثوانٍ بـ Veو 3.1 (1 للطلب).	قراءة (Lite-3.5) ٠,١٧ + تصيير PDF ٠,٠١ + شك (gpt-5.6-sol) ٢٥% ٠,٠٨ + صور (Flash) ٢٠,١٠ (Image ×3) + فيديو Veو 3.1 ٣٢,٠٠	٣٤٠,٣٥	٣٤,٠٣٥
X	للمقارنة: توليفة الجولة الأولى • مرجعي Lite-3.5 + Flash-3.5 شكًا (٢٥%) — ما كان موصى به قبل هذه الجولة.	قراءة (Lite-3.5) ٠,١٧ + تصيير PDF ٠,٠١ + شك (Flash-3.5) ٢٥% ٠,٤٥	٠,٦٣	٦٣

كيف تُقرأ

القراءة والشك معاً لا يكادان يُحسبان (٢٥ \$ في الشهر للعشرة آلاف) — الرقم كله في الصور والفيديو. الصورة الواحدة بـ Flash Image تساوي ٢٧ طلب قراءة؛ ومقطع Veو 3.1 الواحد يساوي ١٢٨٦ طلباً. لذلك القرار التجاري الحقيقي ليس «أي نموذج» بل «هل نوّلد صورة لكل طلب أم عند الطلب فقط»: الخيار C يصبح ربع تكلفته لو وُلدت الصور لطلبات مؤهلة فقط (٢٥%).

الافتراض	القيمة	لماذا
خليط ما يرفعه العميل	٣٠% نصّ ٢٠% رسمة ٢٠% قصاصة ٣٠% مخطط كامل	افتراض تشغيلي — لا بيانات حيّة بعد: الحساسية له صغيرة لأن أعلى سيناريو قراءة (المخطط) يكلف ثلث سنت
نسبة الطلبات التي تستدعي طبقة الشك	٢٥%	الرسومات كلها + جزء من المخططات: يُقاس من أعلام الطبقة الحتمية

الاقتراض	القيمة	لماذا
صور لكل طلب	٣ (صورة لكل غرفة)	متوسط غرف الطلب المنزلي؛ يمكن جعلها عند الطلب فقط
مقاطع لكل طلب	١ × ٨ ثواني	جولة واحدة للطلب
غير مشمول	استضافة الطبقة الحتمية والتخزين (مئات الدولارات شهرياً لا آلافها)، وقت فريق المبيعات في التأكيد البشري، وتصميم/تطوير المنصة. سعر GPT-5.6 مفترض من الدراسة الصفرية.	

الاستخراج: ٤٥ خلية لـ ١ نموذجاً (Google ٢٠٥ · OpenAI ٩٠ · Anthropic ١٢٠) ١,٠٣٦,٢١٥٠ رمز دخل ١,٢٣٣,٢١٢٠ رمز خرج وتفكير ٣٠ خلايا أصلحت بمحلل متسامح ٠٠ خلية معلقة على الرصيد. الصور: ٣٠٠ صورة و٦٠٠ حكم. الفيديو: ١٥ مقطعاً. الإنفاق التقديري: استخراج \$ ١١,٥٦ (Google ٠٤,٩٧ · OpenAI ٠٠,٢٨ · Anthropic ٠٦,٣٢) · صور ٢١,٥٩ · فيديو ١٥,٦٩ · حكم ٣,٠٥ — **٥٢٢ \$ للجولة**. كل مخرج خام محفوظ في `out/matrix_raw/` و `out/images2/` و `out/video2/` ويُعاد التحليل بـ `report_images2.py` و `report_matrix.py`.

الحقيقة المرجعية كما في الجولة الأولى: الأبعاد المطبوعة على `plan1.pdf` بتكبير 300dpi. ورسم يد وقصاصة من المستخدم. البلاط من الموقع العام للشركة: الغرف من Wikimedia Commons. لم تُقس غرفة على الأرض ولم يحكم بشر على صورة.