

أربعة عشر نموذجاً وخمس أدوات صور وخمس فيديو القراءة لم تتغير، والشك والصورة تغيراً

وشعنا الاختبار إلى ثلاث شركات وثلاث مراحل، بحكم أعمى من قاضيين مستقلين على ثلاثمئة صورة. أرخص نموذج ما زال يقرأ الأبعاد المطبوعة بلا خطأ؛ نموذج أرخص منه صار الوحيد الذي يرفض إعطاء رقم لرسم لا تُغلق؛ وأداة صور واحدة فقط تُنقع القاضيين بأن البلاطة هي البلاطة.

نماذج الاستخراج: ١٤ أدوات الصور: ٣٠٠ × ٥ صورة أدوات الفيديو: ٥ الأحكام: ٦٠٠ + الإنفاق: ≈ ٥٢ \$ التاريخ: ٧ سبتمبر ٢٠٢٦

00 الجواب أولاً: التوليفة لم تتغير في القراءة، وتغيرت في الشك والصورة

الخلاصة

وشعنا المصفوفة من ٧ نماذج Google إلى ١٤ نموذجاً من ثلاث شركات، وأضفنا مرحلتين الصورة (٥ أدوات ٢٠ × بلاطة ٣ × غرف = ٣٠٠ صورة بحكم أعمى من قاضيين مستقلين) والفيديو (٥ أدوات ٣ × غرف). النتيجة: أرخص نموذج في القائمة ما زال يقرأ الأبعاد المطبوعة بلا خطأ، لكن ظهر نموذج أرخص منه يُحسن الشك: `gpt-5.6-sol` هو الوحيد الذي يرفض إعطاء رقم للرسم التي لا تُغلق في التشغيلات الخمس كلها. وفي الصور، **Gemini Flash Image** وحده يُنتج ما يقبله القاضيان «البلاطة نفسها» في أكثر من نصف الحالات: Recraft و Stability عند ٢%.

المرحلة	الموصى به	لماذا	ما تغيّر عن ٦ سبتمبر
قراءة الأبعاد (نصّ · قصاصة · مخطط مصوّر)	<code>gemini-3.5- flash-lite</code>	صفر خطأ في كل الغرف المرجعية. ٥-٢ ثوانٍ, ١,٣-٠,٠ سنت — لم يتفوّق عليه أحد من ١٣ نموذجاً آخر	● ثابت
كشف التعارض في رسمّة العميل	<code>gpt-5.6-sol</code>	٥/٥ على الرسمّة الأصلية و٥/٥ على المصغّرة, يعيد <code>null</code> بدل رقم مخمّن, ١٨,٠ سنت مقابل ٢,٠ ل Flash-3.5	● تغيّر كان Flash-3.5 (٤/٥)
الـ PDF الخام	● لا يُرسل	لم نرسله لأي نموذج جديد هذه الجولة — نحوّله بـ <code>pdftoppm -r 150</code> أولاً	● ثابت
صورة الغرفة بالبلاطة	Gemini Flash) Image <code>gemini-3.1- flash-image</code> (	«البلاطة نفسها» ٥٧% عند قاضي OpenAI و ٩٢% عند قاضي Google ١١٠ ثانية ٦,٧٠ سنت. Pro أعلى ٢× بلا فرق, و Lite أرخص لكنه يخطئ البلاطة في النصف	● جديد
فيديو الجولة	ffmpeg حتمي أولاً	انظر VS٠ — القاضيان حكما على ثلاثة إطارات من كل مقطع	● جديد

01 ما اختُبر: ثلاث مراحل، ثلاث شركات، وقاضيان لا يعرفان من رسم

الاستخراج: ٧ نماذج جديدة — `gpt-5.6-luna` · `gpt-5.6-sol` · `gpt-5.6-terra` من OpenAI, و `claude-opus-5` · `claude-sonnet-5` · `claude-haiku-4-5` · `claude-opus-4-5` من Anthropic — على السيناريوهات السبّعة (بلا الـ PDF الخام) بخمس تشغيلات، بنفس البرومبت والحقيقة المرجعية. وأعيد `gemini-3.1-pro-preview` و `gemini-3.8-flash` من خادم DigitalOcean لأن الشبكة المحلية كانت تقطعهما. المعرّفات كلها من قوائم الخدمات لا مخمّنة. Opus-5 و Sonnet-5 بتفكير تكيفي وبلا `temperature` (الواجهة ترفضها): الباقي بحرارة 1.0 كالجولة الأولى.

الصورة: ٢٠ بلاطة حقيقية من niceramics.com (٩ منها عينة مسطحة و١١ لقطة غرفة تعرض البلاطة — وهذا ما يجده العميل فعلاً في الكتالوج) 3×3 غرف فارغة بترخيص مشاع 5×5 أدوات: Gemini Lite/Flash/Pro Image (البلاطة والغرفة كمرجعين في طلب واحد) Recraft V3 (يُصنع style من البلاطة ثم imageToImage على الغرفة) Stability (control/style-transfer): الغرفة أساساً والبلاطة أسلوباً). الترقيم أعمى: والحكم بقاضيين من شركتين غير شركة الأداة قدر الإمكان — gpt-5.6-sol و gemini-3.8-flash — كل يرى البلاطة المرجعية والصورة المولدة ويجب: هل هي البلاطة نفسها؟ أمانة النقشة واللون /٥؟ هل بقيت الغرفة؟

الفيديو: أفضل صورة لكل غرفة بمجموع درجات القاضيين $\rightarrow$ ffmpeg حتمي $\cdot$ Veo 3.1 Fast $\cdot$ Veo 3.1 Lite $\cdot$ Sora 2. ثمانية ثوانٍ 720p. ثم ثلاثة إطارات من كل مقطع إلى القاضيين نفسهما.

ما لم يكتمل — وسببه

٣٠ خلية من Sonnet-5 و Haiku-4.5 و Opus-4.5 على المخطط الكامل (S5/S6) توقفت لأن **رصيد Anthropic (\$٥) نفذ** في منتصفها — محفوظة للاستئناف بعد الشحن. **Mistral OCR 4.1** شغل بعد توثيق إطفاء التدريب (٤ مُدخلات): على المخطط الكامل (S5 و S6) قرأ **جدول العنوان فقط** ولم يلتقط أي رقم بُعد داخل الرسم (٩/٠ في كليهما). وعلى القصاصة قرأ ٣ من ٥ أبعاد مطبوعة (ضاع 600 وقرئ 190 على أنه 210). وعلى الرزمة اليدوية لا شيء (٤/٠) — أقل من ثانيتين للمُدخل. **ليس طبقة قراءة أبعاد:** يعامل الرسم الهندسي كصورة ويُخرج النصوص الجدولية حوله: يسقط. القاضي الثاني كان مقرراً Sonnet-5 فحل محله gpt-5.6-sol للسبب نفسه، ثم أضيف Sonnet-5 قاضياً ثالثاً بعد الشحن (عموده في جدول S٦). Document AI تُخطي بقرار، و gpt-image-2 و FLUX و Runway مُقصاة من الدراسة الصفرية.

02 النص والقصاصة: أربعة عشر نموذجاً، جواب واحد

رسالة العميل بالأبعاد (S1): ١٤/١٤ نموذجاً أعطى ٤٦,٠٠ م في التشغيلات الخمس كلها. الفرق الوحيد هو السعر والزمن: GPT-5.6 عند ٠,٨-٠,٦ سنت، Lite عند ٠,٩، Opus-5 عند ٢,٦. قصاصة المخطط (S3):

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الحكم
Lite-3.1 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٢,٣	٠,١٢	● صفر خط
Lite-3.5 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٢,٣	٠,١٢	● صفر خط
Flash-3.5 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	١٠,١	١,١٣	● صفر خط
Flash-3.6 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٨,٠	٠,٨٣	● صفر خط
Flash-3.7 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٤,٢	٠,٥٣	● صفر خط
Flash-3.8 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٧,٨	٠,٥٨	● صفر خط
Pro-3.1 Google	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	١٧,٢	٣,٧٥	● صفر خط
GPT-5.6-luna OpenAI	٥/٥	٣-٣	٣٦,٦	٢/٣	١,٨	٥,٨	٠,١١	● جزئي

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الحكم
GPT-5.6-sol OpenAI	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٨,٩	٠,١١	● صفر خط
GPT-5.6-terra OpenAI	٥/٥	٤-٣	٣٦,٣	٣/٣	٠,٠	٤,٨	٠,٠٩	● صفر خط
Opus-5 Anthropic	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	١٤,٢	٣,٧٤	● صفر خط
Sonnet-5 Anthropic	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٢٤,٧	٢,٦١	● صفر خط
Haiku-4.5 Anthropic	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٥,٨	٠,٥١	● صفر خط
Opus-4.5 Anthropic	٥/٥	٣-٣	٣٦,٣	٣/٣	٠,٠	٧,٢	٢,٤٥	● صفر خط

الخطأ الوحيد في القصاصة كان **gpt-5.6-luna** الذي قرأ الحمام ٦,٣ بدل ٦,٠ في التشغيلات الخمس (٣٦,٦ بدل ٣٦,٣) — و **gpt-5.6-terra** الذي أضاف فراغاً رابعاً غير موجود في تشغيلة. Haiku-4.5 صحيح في الوسيط لكنه الوحيد الذي تشّتت (٥% بين التشغيلات). ● مؤكّد ١٤٠ نموذجاً × ٥

03 الرسمة التي لا تُغلق: من يقول «لا أعرف»؟

الرسمة نفسها من الجولة الأولى: ارتفاع اليسار ٣ م واليمين ١ + ٢,٥ = ٣,٥ م، فلها ثلاثة أجوبة «صحيحة» (٠,١١,٠). (١٣,٢٥٠ ١٣,٠) ولا جواب واحد. المقياس هنا ليس الرقم، بل: هل صرّح النموذج بالتعارض؟

النموذج	كشف التعارض	القيم التي أعطاها	ثانية	سنت	الحكم
Lite-3.1	٠ / ٥	١٣,٢٥٠١٣,٠	٥,٦	٠,١٠	صامت ●
Lite-3.5	٠ / ٥	١١,٠	٤,٨	٠,٠٩	صامت ●
Flash-3.5	٤ / ٥	١٣,٢٥٠١١,٠	٢٠,٠	٢,٠١	يكشف ●
Flash-3.6	٠ / ٥	١٣,٠٠١١,٠	٣٠,٧	٢,٠٧	صامت ●
Flash-3.7	٠ / ٥	١٦,٠٠١٥,٠٠١٣,٢٥٠١١,٥	١٥,٤	١,٤٠	صامت ●
Flash-3.8	٢ / ٥	١٣,٢٥٠١١,٥٠١١,٠	٦٣,١	٨,٢٣	أحياناً ●
Pro-3.1	٤ / ٥	١٤,٢٥٠١٣,٢٥٠١١,٥	٣٥,٩	٦,٨١	يكشف ●
GPT-5.6-luna	٣ / ٥	١١,٥٠١١,٠	١٧,٠	٠,٢٠	أحياناً ●
GPT-5.6-sol	٥ / ٥	لا رقم	١٦,٣	٠,١٨	يكشف ●
GPT-5.6-terra	٠ / ٥	١٣,٠٠١١,٠	١٨,١	٠,٢٣	صامت ●
Opus-5	٠ / ٥	١٣,٠٠١١,٠	٢٣,٦	٧,٣٥	صامت ●
Sonnet-5	٠ / ٥	١٣,٠٠١١,٠	٢٩,٥	٣,٨٦	صامت ●
Haiku-4.5	٠ / ٥	٢٢,٥٠١٦,٢٥٠١٦,٠٢٥٠١٤,٧٧٥	٥,٧	٠,٥٣	صامت ●
Opus-4.5	٠ / ٥	١٣,٠٠١٢,٢٥	١٤,١	٣,٣٨	صامت ●

النتيجة الجديدة

gpt-5.6-sol كشف التعارض في ٥/٥ — وفعل ما لم يفعله أحد: أعاد floor_area_m2: null وكتب في الدليل «الارتفاع الكلي المكتوب ٣ م بينما ٢,٥ + ١ = ٣,٥ م».

Flash-3.5 و Pro-3.1 يكشفان ٤/٥ لكنهما يعطيان رقماً مع ذلك. عائلة Claude الأربعة صامتة ٠/٥ وتعطي رقماً ثابتاً (١١,٠ أو ١٣,٠) بثقة — و Haiku-4.5 أسوأ: أرقام من ١٤,٨ إلى ٢٢,٥ لا يفترها أحد. على النسخة المصغرة (S2b) ١٦٠px تكرر الترتيب نفسه: sol ٥/٥, luna ٤/٥, Pro ٣/٥.

ما يعنيه هذا للتصميم: طبقة «الرأي الثاني» لا تحتاج نموذجاً غالياً مفكراً؛ تحتاج نموذجاً مسموحاً له أن يرفض. sol يكلف ١/٨ سنت للاستدعاء — عُشر Flash-3.5 وثلاثون ضعف أرخص من Pro.

● رسمة واحدة — يُعَمَّم بعد ١٠ رسومات

04 المخطط الكامل: من يقرأ الرقم المطبوع، ومن «يقيس» بدلاً منه

الدور الأرضي كصورة راستر (S5) والـ PDF نفسه بعد تصييرنا (S6). خمس غرف مرجعية أبعادها مطبوعة على الرسم بالسنتيمتر. المقياس: كم غرفة أصابها النموذج بخطأ $\geq 2\%$.

S5 — صورة راستر للدور الأرضي

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف %	ثانية	سنت	الحكم
Lite-3.1 Google	٥/٥	١٤-١٢	٢٧١,٧٤	٥/٥	٠,٠	٦,٥	٠,٢٨	● صفر
Lite-3.5 Google	٥/٥	١٣-١٣	٢٨٣,٦٧	٥/٥	٠,٠	٥,١	٠,٢٩	● صفر
Flash-3.5 Google	٥/٥	١٥-١٣	٣٣٨,٧٩	٤/٥	٤,٠	٢٤,٢	٣,١١	● جزئي
Flash-3.6 Google	٥/٥	١٦-١٤	٣٢٤,٣٦	٥/٥	٠,٠	٢٠,٦	٢,٢٩	● صفر

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الحكم
Flash-3.7 Google	٥/٥	١٣-١١	٣٢٥,٢١	٥/٥	٠,٠	٨,٣	١,٢٠	● صفر
Flash-3.8 Google	٥/٥	١٣-١١	٢٥٣,٧٢	٥/٥	٠,٠	٩,٥	١,٣٩	● صفر
Pro-3.1 Google	٥/٥	١٤-١٣	٢٣٥,٨٤	٥/٥	٠,٠	٦٣,٠	١٢,١٩	● صفر
GPT-5.6-luna OpenAI	٥/٥	١٦-١٤	٢٨٢,٤٦	١/٥	٨,٥	٤٩,٠	٠,٦٠	● ضعيف يقرأ الأثر المطبوع خطأً (١٠) بدل ٥٦٠ بدل ٥٠٠
GPT-5.6-sol OpenAI	٥/٥	١٨-١٤	٢٢٧,١١	٢/٥	٧,٣	٨٠,٨	٠,٧٢	● ضعيف يقرأ الأثر المطبوع خطأً (١٠) بدل ٥٦٠ بدل ٥٠٠
GPT-5.6-terra OpenAI	٥/٥	١٥-١٢	٢١٦,٦٩	٢/٥	١٣,٤	٤٠,٨	٠,٥٤	● ضعيف يقرأ الأثر المطبوع خطأً (١٠) بدل ٥٦٠ بدل ٥٠٠

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الحكم
Opus-5 Anthropic	٥/٥	١٨-١٥	٣٣٧,٤٢	٤/٥	٤,٠	٧٦,٣	١٧,٩٠	● جزئي المطبخ مقيس الرسم لا من الرق المطبو
Sonnet-5 Anthropic	١/٥	١٥-١٥	٣٩٥,٨٦	٤/٥	٤,٠	٢٠١,٩	١٦,٧٥	● جزئي
Haiku-4.5 Anthropic	٥/٥	١٣-١٢	٣١٢,١٣	٠/٥	٧٩,١	١٥,٣	١,١٩	● صغير
Opus-4.5 Anthropic	٥/٥	١٤-١٤	٢١٣,٢٤	٠/٥	٧٢,٤	٢٠,٨	٦,١١	● صغير

S6 — الـ PDF نفسه بعد pdftoppm -r 150

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الح
Lite-3.1 Google	٥/٥	١٤-١٣	٢٥٩,٨٢	٥/٥	٠,٠	٥,٩	٠,٢٩	●
Lite-3.5 Google	٥/٥	١٥-١٥	٣٦٣,٨١	٤/٥	٤,٠	٥,٣	٠,٣٣	●
Flash-3.8 Google	٥/٥	١٤-١٢	٢٥٦,٨٨	٥/٥	٠,٠	١١,٣	١,٤٤	●

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الح
Pro-3.1 Google	٥/٥	١٨-١٢	٢٦٦,٦٧	٥/٥	٠,٠	٥٢,٧	١٠,٧٠	●
GPT-5.6-luna OpenAI	٥/٥	١٦-١٣	٢٩٦,٣٢	٣/٥	١٠,٢	٣٥,٣	٠,٥٦	●
GPT-5.6-sol OpenAI	٥/٥	٢٠-١٥	٢٢١,٢٥	٤/٥	٢,٢	٩٨,٣	٠,٧٥	●
GPT-5.6-terra OpenAI	٥/٥	١٧-١٢	٢٨١,٤٨	٣/٥	٣,٧	٣٨,٠	٠,٥٣	●
Opus-5 Anthropic	٥/٥	١٦-١٥	٣٧١,٧٨	٥/٥	٠,٠	٦١,١	١٦,٥٢	●

النموذج	ناجح	فراغات	المجموع م ²	مطابق	خطأ الغرف%	ثانية	سنت	الح
Sonnet-5 Anthropic	٤/٥	١٥-١٥	٣٨٨,٣٦	٤,٠/٥	٧,٥	١٣٨,٧	١٣,٨١	●
Haiku-4.5 Anthropic	٥/٥	١٤-١٢	٢١٩,٠	٠/٥	٥٤,٥	١٤,٧	١,٢١	●
Opus-4.5 Anthropic	٥/٥	١٦-١٤	٢٣٥,٧١	١/٥	٢٦,٧	٢٣,٠	٦,٤٢	●

تفسير

عائلة GPT-5.6 تجد الغرف الخمس كلها لكنها **تقرأ الأرقام المطبوعة خطأ** — 875×590 بدل ٥٦٠. 430×500 بدل ٥٥٠. 250×200 بدل ٢٢٠ — وهي الأرقام نفسها التي أخطأتها Gemini على الـ PDF الخام في الجولة الأولى. الفرق أن Gemini تُصيبها على الصورة وGPT لا. وتستغرق ٤٠-١٠٠ ثانية للمخطط (تفكير طويل) مقابل ٥ ثوانٍ لـ Lite. Opus-5 يقرأ أربعاً من خمس صحيحة، لكنه في المطبخ ترك الرقم المطبوع و**قاس من الرسم** فأعطى ١٥,٠ بدل ٢٣,٦٥ — ثم أصاب الخمس على S6 بتكلفة ١٦,٥ سنت و٦١ ثانية. Lite-3.5 وFlash-3.8 يصيبان الخمس بأقل من سنت ونصف. بقية عائلة Claude بعد الشحن: **Sonnet-5** دقيق حين يُكمل (٤/٥ على S6 بخطأ ٧,٥%) لكنه **استنفد سقف ١٦ ألف رمز** في ٤ من ٥ تشغيلات على S5 (تفكير تكتيفي يلتهم الميزانية) عند ١٤٠-٢٠٠ ثانية و١٧-١٤ سنتاً؛ **Haiku-4.5** يجد الغرف الخمس لكن بخطأ ٥٥-٧٩% في مساحاتها (٠/٥ مطابق) — يقرأ الأرقام ولا يربطها بالغرفة الصحيحة؛ **Opus-4.5** ١/٥ مطابق بخطأ ٢٧%. لا واحد منها يقترب من Lite.

05 Flash-3.8 وPro-3.1 من شبكة الإنتاج: الحكم المعلق خُسم

في الجولة الأولى قُطع Pro-3.1 ١١ مرة من ٢٥ وُعُلّق الحكم عليه. أُعيد النموذجان من droplet في DigitalOcean: **صفر قطيعة شبكية** في ٦٣ خلية (ثلاث 503 من خادم Google نفسه أُعيدت فنجحت). فتبين أن Pro-3.1 يصيب الغرف الخمس ٥/٥ على S5 وS6 ويكشف تعارض الرسمة ٤/٥ — لكنه يستغرق ٣٥-

٨٣ ثانية ويكلف ٣-١٥ سنتاً للاستدعاء، أي لا يضيف شيئاً على Lite-3.5 في القراءة ولا على sol في الشكّ. وبثلاثين ضعف سعرهما. Flash-3.8 ثابت كما كان، والقطيعة التي أصابته على صور الجوال الكبيرة كانت شبكية أيضاً.

الدرس الذي يهّم مسار الإنتاج: الشبكة المحلية تُسقط أي اتصال يطول نحو دقيقتين — أصابت OpenAI أيضاً على S5/S6 (٦/٦ قبل الانتقال إلى الخادم). أي قياس زمن أو قطيعة يُجرى من الإنتاج لا من المكتب.

● مؤكّد ٦٣٠ + ٧٠ خلية من الخادم

06 الصور: أداة واحدة تُقنع القاضيين، واثنان لا تُقنعان أحداً

٣٠٠ صورة، كلّ منها حُكمت مرتين بلا معرفة الأداة. السؤال الذي يهّم العميل واحد: هل هذه هي البلاطة التي في الكتالوج؟

الأداة	صور	«البلاطة نفسها» — قاضي OpenAI	— قاضي Anthropic	— قاضي Google
Gemini Lite Image	٦٠/٦٠	٣٥%	٣٢%	٦٨%
Gemini Flash Image	٦٠/٦٠	٥٧%	٣٠%	٩٢%
Gemini Pro Image	٦٠/٦٠	٥٣%	٢٧%	٩٢%
Recraft V3	٦٠/٦٠	٢%	٠%	٢%
Stability	٦٠/٦٠	٢%	٣%	٣%

ثلاثة قضاة من ثلاث شركات، وثلاث صرامات: قاضي Google أكثر تساهلاً مع صور Google (٩٢٪)، قاضي OpenAI في الوسط (٥٧٪)، وقاضي Anthropic (Sonnet-5) الأشدّ — يعطي الثلاثة من Gemini نحو ٣٠٪ بلا فرق بينها (٣٢٪ ٣٠٪ ٢٧٪) ويُبقي Recraft وStability عند ٠٪ و٣٪. ما يتَّفَق عليه الثلاثة بلا استثناء: **Stability وRecraft يسقطان** (٩٣-٩٨٪ اتفاق على «ليست البلاطة»). ما يختلفون فيه: هل Flash أفضل من Lite وPro — قاضيان يقولان نعم بفارق واضح، والثالث لا يرى فرقاً. لذلك الترتيب المعتمد **Gemini » Recraft ≈ Stability** مؤكّد، وتفضيل Flash داخل عائلة Gemini • مرجّح لا مؤكّد — يُحسم بعيّنات مسطّحة وبشر يحكمون.



بلاطة زهور مائية (T13) في المطبخ نفسه: المرجع ثم Gemini Lite · Flash · Pro · Recraft · Stability. الثلاثة الأولى تنقل النقشة: Recraft يضع بلاطة أخرى: Stability يترك الأرضية خشباً ويرسم الزهور على الجدار.

ما الذي يُفشل الأداة؟


الأداة	مرجع عيّنة مسطّحة (٩ بلاطات) نفسها/٠ نقشة/٥	مرجع لقطة غرفة (١١ بلاطة) مطبخ نفسها/٠ غرفة/٥	حقام
Gemini Lite Image	٢,٨ • ٢٦٪	٣,٠ • ٤٢٪	٣,٥ • ٣٥٪ ٣,٤ • ٤٠٪
Gemini Flash Image	٣,٧ • ٦٧٪	٣,١ • ٤٨٪	٤,٠ • ٧٠٪ ٤,٠ • ٥٠٪
Gemini Pro Image	٣,٦ • ٦٣٪	٣,٢ • ٤٥٪	٤,٢ • ٦٠٪ ٣,٠ • ٤٥٪

الأداة	مرجع عينة مسطحة (٩ بلاطات) نفسها% · نقشة/٥	مرجع لقطة غرفة (١١ بلاطة) مطبخ نفسها% · غرفة/٥	حمام
Recraft V3	٠,٦ · %٤	٠,٥ · %٠	٣,٩ · %٠
Stability	١,١ · %٠	١,٢ · %٣	٢,٥ · %٠

- **نوع المرجع يحسم:** Pro و Flash يصيبان «البلاطة نفسها» في ثلثي الحالات حين يكون المرجع عينة مسطحة. وفي أقل من النصف حين يكون لقطة غرفة من الكتالوج — لأن الأداة لا تعرف أي سطح في اللقطة هو البلاطة. **الكتالوج الحالي أغلبه لقطات غرف** (١١/٢٠) — وهذا بند تجهيز بيانات، لا بند نموذج.
- **Lite يخطئ البلاطة لا الغرفة:** يحفظ الغرفة (٣,٧/٥) لكنه يضع نقشة قريبة لا مطابقة (٣٥%). أرخص بالنصف من Flash. ولا يساوي الفرق.
- **Pro لا يفوق Flash** (٥٣% مقابل ٥٧%) وهو أبطأ ٢× وأعلى ٢×، وأخرج في بعض الحقامات صورة مزدوجة جنباً إلى جنب.
- **Recraft** يحفظ الغرفة جيداً (٣,٨/٥) لكن **style** المستخرج من البلاطة يُنتج «بلاطة بروح المرجع» لا المرجع — ٢% فقط. **Stability** بـ style-transfer إمّا يُتلف الغرفة (الإعداد الافتراضي) أو يطلي الجدران والسقف بالنقشة ولا يفهم «الأرضية فقط» — حفظ الغرفة ١,٩/٥. كلاهما يسقط بغض النظر عن السعر.



Gemini Lite Image · kitchen · T11 · IMG-087 · 16.0/20



Gemini Lite Image · bathroom · T14 · IMG-161 · 16.0/20



Gemini Lite Image · standard · T17 · IMG-061 · 16.0/20



Gemini Flash Image · kitchen · T18 · IMG-091 · 16.0/20



Gemini Flash Image · bathroom · T14 · IMG-069 · 17.0/20



Gemini Flash Image · standard · T13 · IMG-096 · 17.0/20



Gemini Pro Image · kitchen · T14 · IMG-004 · 16.0/20




Gemini Pro Image · bathroom · T13 · IMG-086 · 17.0/20




Gemini Pro Image · standard · T04 · IMG-233 · 17.0/20



Recraft V3 · kitchen · T15 · IMG-114 · 16.0/20




Recraft V3 · bathroom · T15 · IMG-031 · 10.0/20




Recraft V3 · standard · T04 · IMG-218 · 11.0/20



Stability · kitchen · T19 · IMG-211 · 11.0/20



Stability · bathroom · T15 · IMG-028 · 12.0/20



Stability · standard · T20 · IMG-099 · 16.0/20

أفضل صورة لكل أداة (صفوف) في كل غرفة (أعمدة) بمجموع درجات القاضيين — حتى «أفضل» Recraft وStability ليست البلاطة المطلوبة.

لكل غرفة الصورة الأعلى درجةً عند القاضيين (, bathroom: IMG-244 , kitchen: IMG-126 standard :IMG-096). المقطع ٨ ثوانٍ 720p. والحكم على ثلاثة إطارات (البداية · المنتصف · النهاية) مقابل الصورة المصدر.

الأداة	مقاطع	النقشة ثابتة — قاضي OpenAI	— قاضي Google	ثانية	\$ للثلاثة	ملاحظة
ffmpeg (حتمي) ffmpeg zoompan	٣/٣	٣/٣ · ٤,٣	٣/٣ · ٤	١	٠,٠٠	
Veo 3.1 veo-3.1-generate-preview	٣/٣	٢/٣ · ٣	٢/٣ · ٣,٧	٦٨	٩,٦٠	
Veo 3.1 Fast veo-3.1-fast-generate-preview	٣/٣	٠/٣ · ١,٧	١/٣ · ٣	٥٧	٢,٤٠	
Veo 3.1 Lite veo-3.1-lite-generate-preview	٣/٣	١/٣ · ٣	١/٣ · ٣,٣	٤٦	١,٢٠	
Sora 2 sora-2	٣/٣	٢/٣ · ٣,٣	١/٣ · ٣	١٢٦	٢,٤٩	

الإطار الأول في كل مقطع توليدي يطابق المصدر (٤-٥/٥ عند القاضيين) لأنه الصورة نفسها تقريباً؛
التدهور يبدأ في المنتصف ويكتمل في الإطار الأخير: بلاطة الحمام الشيفرونية تحوّلت عند Veo 3.1
 Fast إلى بلاطة أخرى (٥ → ١). وعند Sora في الحمام اختفت من الإطار الأخير (٤ → ٠). الغرفة الأسهل
 هي المطبخ (بلاطة خشبية النقشة، حركة أمامية بسيطة) — هناك ثبت Veo 3.1 و Sora عند
 القاضيين. الترتيب: **Veو Fast > Veو Lite > Sora 2 ≈ Veو 3.1 > ffmpeg**. و Veو 3.1 يكلف
 \$ ٣,٢ للمقطع مقابل \$ ٨٣,٠ لـ Sora و صفر لـ ffmpeg.



الحمام: الإطار الأول والأوسط والأخير لأربع أدوات. ffmpeg (يسار) لا يتغيّر: الثلاثة الأخرى تبدأ صحيحة وتنتهي
 ببلاطة أخرى أو بلا بلاطة.

ffmpeg لا يعيد رسم بكسل واحد — النقشة ثابتة **بالتعريف** وبتكلفة حوسبة تُقاس بأجزاء السنت (٦,٠ ثانية
 للمقطع). التوليدي يُقاس بما يفعله بالنقشة، لا بجمال الحركة.

gemini-3.5-flash-lite

القراءة

كل مُدخَل يبدأ هنا (نصّ · قصاصة · مخطط مصوّر · PDF بعد تصديرنا). ١٣ نموذجاً آخر لم يتفوّق عليه في غرفة واحدة، وأغلبها أبطأ وأعلى بعشرات الأضعاف.

كود، لا نموذج

التحقّق الحتمي

إغلاق المضلّع، مطابقة العدّ، رفض التشغيلية الشاذّة، ومحلّل JSON متسامح — ثلاث خلايا هذه الجولة (Flash-3.5، ٢× Opus-5) أخرجت JSON صحيحاً بفاصلة زائدة أو محرف تحكّم، والمحلّل الصارم يراها فشلاً.

gpt-5.6-sol

الشكّ — عند العلم فقط

حين ترفع الطبقة الحتمية علماً: يُستدعى ليقول إن كانت الرسمة لا تُغلق — ويقولها ٥/٥ ويرفض الرقم. ١٨، سنت و١٦ ثانية. مزوّد ثانٍ من شركة أخرى = احتياط تشغيلي أيضاً.

gemini-3.1-flash-image + عيّينات مسطّحة

الصورة

البلاطة والغرفة في طلب واحد، ٦,٧ سنت، ١١ ثانية. الشرط الذي يرفع الإصابة من النصف إلى الثلثين ليس النموذج بل تصوير كل موديل عيّنةً مسطّحة بدل لقطة الغرفة.

ffmpeg على الصورة المعتمّدة

الفيديو

الحكم في VS: التوليدي يُضاف فقط حيث يثبت القاضيان أن النقشة لم تتغيّر.

09 ما انقُتل، وما لم يُتحقّق، وما مصدره واحد

انقُتل في هذه الجولة

- «Flash-3.5 هو أفضل كاشف للتعارض» — sol يفوقه (٥/٥ مقابل ٤/٥) ويرفض الرقم بدل أن يعطيه، بعُشر التكلفة.

- «Pro-3.1 محبوب شبكياً فحكمه معلق» — من الخادم لا قطيعة، ولا ميزة.
- «النموذج الأعلى يقرأ المخطط أفضل» — Opus-5 قاس المطبخ من الرسم متجاهلاً الرقم المطبوع: GPT-5.6 أخطأ الأرقام المطبوعة نفسها التي أخطأتها Gemini على الـ PDF الخام.
- «Recraft مرشح امتثالياً فيجرب» — امتثاله لا يشفع له: ٢% «البلاطة نفسها».

غير متحقق

- أسعار GPT-5.6 (\$٠,٢٠/١,٢٠ للمليون) مفترضة من الدراسة الصفريّة — الرموز مقيسة، السنوات لا. أسعار Gemini وAnthropic الصور وVeO منشورة.
- ٣٠ خلية Anthropic على المخطط الكامل لم تكتمل (نفاد الرصيد) — الجدولان S5/S6 يخلوان من Sonnet-5 وHaiku وOpus-4.5.
- القاضيان نموذجان لا بشر. اتفاقهما على الفاشل تام، واختلافهما على الناجح واضح — فالنسب المطلقة تُقرأ كترتيب لا كقياس.
- Sora 2 بسعر مفترض (\$٠,١٠/ث) من الدراسة الصفريّة.

مصدر واحد

- رسمة يد واحدة تحكم كل استنتاج S٣٠. عشر رسومات من عملاء حقيقيين قبل تثبيت sol في التصميم.
- مخطط واحد (الدور الأرضي نفسه) لكل نتائج ES٤٠.
- ثلاث غرف فقط، ومصوَّرة بترخيص مشاع لا بجمال العميل. غرفة العميل الحقيقية (إضاءة رديئة، زاوية عشوائية) لم تُختبر.

01 شحن رصيد Anthropic (~\$ ١٠) واستئناف الـ ٣٠ خلية + إعادة حكم Sonnet-5 على الصور كقاضٍ ثالث.

يُكمل الجدولين ويُثبت أن ترتيب الصور لا يتغيّر بقاضٍ من شركة ثالثة.

02 إسقاط «OCR متخصص» من بدائل طبقة القراءة في `ai-estimator-spec.md`.

Mistral OCR 4.1 لا يقرأ أرقام الأبعاد داخل الرسم (٩/٠ على المخطط الكامل) — نماذج الرؤية العامة تفعل، وأرخصها بصفر خطأ.

03 إضافة `gpt-5.6-sol` إلى `ai-estimator-spec.md` بوصفه طبقة الشكّ، مع سياسة «null أفضل من رقم مخمّن».

تغيير في العقد بين الطبقات: الطبقة الحتمية تقبل null وتساءل العميل بدل أن تُقدّر.

04 بند تجهيز بيانات في BRD v1.1.0: عيّنة مسطّحة واحدة لكل موديل (٧٠-١٠٠ موديل).

يرفع إصابة الصورة من النصف إلى الثلثين بلا تغيير نموذج — أرخص تحسين في الجولة كلها.

05 محلّ JSON متسامح في طبقة الاستخراج (فاصلة زائدة · محرف تحكّم · شظيّة بعد الكائن).

ثلاث خلايا هذه الجولة كانت ستُسجّل فشلاً وهي صحيحة.

06 عشر رسومات وعشر لقطات غرف من عملاء حقيقيين قبل أي قرار نهائي.

كل استنتاج في ٣٨ و ٦٨ مبني على مُدخّل واحد أو ثلاثة.

الاستخراج: ٤١٥ خلية لـ ١٤ نموذجاً (٢٠٥ Google · ٩٠ OpenAI · ١٢ Anthropic) · ١,٣٦,٢١٥ رمز دخل · ١,٢٣٣,٢١٢ رمز خرج وتفكير · ٣ خلايا أصلحت بمحلّ متسامح · ٣٠ خلية معلّقة على الرصيد. الصور: ٣٠٠ صورة و ٦٠٠ حكم. الفيديو: ١٥ مقطعاً. الإنفاق التقديري: استخراج \$ ١١,٥٦ (Google ٤,٩٧ · OpenAI ٠,٢٨ · Anthropic ٦,٣٢) · صور ٢١,٥٩ \$ · فيديو ١٥,٦٩ \$ · حكم ٣,٥٥ \$ — ≈ ٥٢ \$ للجولة. كل مخرج خام محفوظ في `out/matrix_raw/` و `out/images2/` و `out/video2/` ويُعاد التحليل بـ `report_images2.py` و `report_matrix.py`.

الحقيقة المرجعية كما في الجولة الأولى: الأبعاد المطبوعة على **plan1.pdf** بتكبير 300dpi، ورسمه يد وقصاصة من المستخدم.
البلاط من الموقع العام للشركة: الغرف من Wikimedia Commons. لم تُنقَسْ غرفة على الأرض ولم يحكم بشر على صورة.